INFORME DEL MODELO DE DETECCIÓN DE GROOMING

Clasificador Naive Bayes multinomial · Python + scikit-learn

Descripción del modelo

Se usó el conjunto de 20 mensajes provisto (10 etiquetados como *grooming* y 10 como *no grooming*). Cada mensaje se convirtió en un conteo de palabras (*bag of words*, con `CountVectorizer`) y se entrenó un clasificador **Multinomial Naive Bayes**. No se eliminaron las *stopwords*, porque palabras como “no”, “nadie” o “solo” son justamente las que distinguen frases de ocultamiento como “no le digas a nadie”.

Los datos se dividieron al azar en 14 mensajes de entrenamiento (70%) y 6 de prueba (30%), manteniendo la misma proporción de cada clase (división estratificada, semilla `random_state=2` para que el resultado sea reproducible).

1- Precisión del modelo (Accuracy)

Accuracy = 1.00 (100%). El modelo clasificó correctamente 6 de los 6 mensajes del conjunto de prueba.

2- Reporte de clasificación

Clase	Precision	Recall	F1-score	Soporte
grooming	1.00	1.00	1.00	3
no grooming	1.00	1.00	1.00	3
Promedio macro	1.00	1.00	1.00	6
Promedio ponderado	1.00	1.00	1.00	6

Precision: de los mensajes que el modelo marcó con una clase, cuántos eran realmente de esa clase. **Recall**: de los mensajes que realmente eran de una clase, cuántos detectó. **F1-score**: promedio armónico entre ambas. **Soporte**: cantidad de mensajes de cada clase en la prueba.

El modelo tuvo un rendimiento perfecto en este conjunto de prueba.

3- Matriz de confusión

	Predicho: grooming	Predicho: no grooming
Real: grooming	3	0
Real: no grooming	0	3

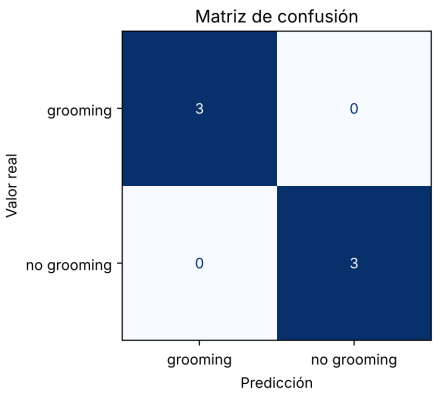

Los 3 mensajes de grooming y los 3 de no grooming del conjunto de prueba se clasificaron correctamente: no hubo **falsos negativos** (grooming que pasa sin detectar, el error más grave en

este contexto) ni **falsos positivos** (mensajes inocentes marcados como sospechosos).

Mensajes del conjunto de prueba:

Mensaje	Real	Predicción
“No hace falta que le digas a nadie que hablamos tanto.”	grooming	grooming
“¿Tenés ganas de salir a andar en bici mañana?”	no grooming	no grooming
“Mandame una foto tuya, pero que nadie más la vea.”	grooming	grooming
“¿Podés mostrarme cómo estás vestida ahora?”	grooming	grooming
“¿Cómo te fue en el examen de historia?”	no grooming	no grooming
“¿Querés hacer una videollamada para estudiar juntos?”	no grooming	no grooming

4- Clasificación de nuevos mensajes

Mensaje	Clasificación	P(grooming)
“¿Podés mandarme una foto tuya? No se la muestres a nadie.”	grooming	99%
“¿Jugamos Minecraft esta tarde?”	no grooming	3%
“No le digas a tus papás que hablamos, ¿sí?”	grooming	100%
“¿Terminaste el trabajo práctico de historia?”	no grooming	3%

La columna P(grooming) es la probabilidad que el modelo asigna a que el mensaje sea grooming. Los mensajes que piden fotos o piden ocultar la conversación a los padres quedan con probabilidades cercanas al 100%; los de temas escolares o de juegos, cercanas a 0%.

5- Observaciones y limitaciones

Robustez del resultado. Con solo 6 mensajes de prueba, el accuracy depende mucho de qué mensajes caen en la prueba: un solo error lo baja al 83%. Para medirlo se repitió el sorteo 70/30 con 200 semillas distintas: el accuracy promedio fue de **88%** (mínimo 50%, máximo 100%), y en el 50% de los sorteos el acierto fue perfecto. Con validación cruzada de 5 particiones el promedio fue 80%. Es decir, el modelo funciona bien, pero el 100% de esta división no debe tomarse como su rendimiento real esperado.

Mensajes difíciles. En algunos sorteos falla “¿Estás solo en casa ahora?”, porque no comparte palabras clave (“nadie”, “foto”, “secreto”) con el resto de los mensajes de grooming: el modelo solo reconoce patrones que ya vio.

Mensaje repetido. “¿Jugamos Minecraft esta tarde?” también forma parte del dataset de entrenamiento, por lo que no es estrictamente un mensaje nuevo.

Uso real. Para usarlo en una plataforma haría falta un dataset mucho más grande y variado, y conviene que el modelo funcione como alerta para revisión humana, priorizando el recall de la clase grooming (no dejar pasar casos).